CMAgent: 단일세포 RNA-seq 주석을 위한 LLM 기반 세포 유형-마커 관계 큐레이션 에이전트

김동후[O†], 김명관[†], 신지영, 오민식
명지대학교
{donghoo1106, kmg9883, tlswl313, msoh}@mju.ac.kr

CMAgent: An LLM-Based Curation Agent for Cell Type-Marker Relationships in Single-Cell RNA-seq Annotation

Donghoo Kim[O†], Myeongkwan Kim[†], Jiyeong Shin, Minsik Oh
Myongji University
{donghoo1106, kmg9883, tlswl313, msoh}@mju.ac.kr

요 약

세포 유형 특이적 마커 유전자는 단일세포 전사체 분석에서 세포 유형 주석에 핵심적으로 사용되지만, 문헌 증가로 인해 수동 큐레이션만으로 최신 정보를 유지하기 어렵다. 본 연구는 PubMed 문헌에서 마커 관련 문장을 선별하고, 세포 유형-마커 쌍과 근거 문장을 구조화하여 데이터베이스로 정리하는 LLM 기반 큐레이션 에이전트 CMAgent를 제안한다. CMAgent는 문장 라벨 정제를 통해 마커 관련 문장 후보를 확장하고, 프롬프트 기반 추출을 통해 구조화된 세포 유형-마커 후보를 수집한다. 실험 결과, 기존 문헌 기반 추출 시스템보다 마커 관련 문장 회수와 세포 유형-마커 쌍 추출에서 개선 가능성을 보였으며, 수동 주석 부담을 줄일 수 있음을 확인하였다.

1. 서 론

단일세포 RNA sequencing (scRNA-seq) 분석에서 세포 유형 주석은 각 세포군의 생물학적 의미를 해석하고 후속 분석을 수행하기 위한 핵심 단계이다. 세포 유형 주석은 일반적으로 클러스터별 마커 유전자를 확인한 뒤, 이를 문헌이나 마커 데이터베이스의 세포 유형 정보와 비교하여 해석하는 방식으로 수행된다. CellMarker 2.0 [1], singleCellBase [2]와 같은 데이터베이스는 세포 유형별 마커 정보를 제공하지만, 대부분 수동 큐레이션에 기반하므로 빠르게 증가하는 생의학 문헌의 최신 결과를 지속적으로 반영하는 데 한계가 있다. 또한 마커 유전자 정보는 여러 문헌에 분산되어 있고, 조직 및 세포 유형에 따라 용어와 근거 수준이 달라 분석자가 직접 문헌 근거를 확인해야 하는 부담이 크다. 따라서 반복적이고 시간이 많이 소요되는 문헌 검토와 세포 유형-마커 쌍 주석 과정을 자동화할 필요가 있다.

이러한 문제를 해결하기 위해 생의학 문헌에서 세포 유형과 마커 유전자 정보를 자동 추출하려는 자연어처리 기반 연구가 진행되어 왔다. MarkerGeneBERT는 PubMed 문헌을 수집·파싱한 뒤 문장 단위로 마커 관련성을 분류하고, named entity recognition (NER)을 통해 세포 유형과 마커 유전자 정보를 추출하는 문헌 기반 세포 마커 추출 시스템이다 [3]. 본 연구에서 positive (POS) 문장은 단순히 세포 유형과 유전자가 함께 언급된 문장이 아니라, 해당 유전자가 특정 세포 유형을 식별하거나 특징짓는 마커로 제시되는 문장으로 정의한다. 반대로 negative (NEG) 문장은 세포 유형 또는 유전자만 단독으로 언급되거나, 둘 다 등장하더라도 세포 유형-마커 관계가 명확히 지지되지 않는 문장이다.

기존 문헌 기반 추출 흐름은 세포 마커 후보 수집을 자동화하기 위한 기반을 제공하지만, 실제 활용에서는 두 가지 한계가 남아 있다. 첫째, marker sentence classifier (마커 관련 문장 분류기)가 POS 문장을 충분히 회수하지 못하면 후속 세포 유형-마커 쌍 추출에 사용할 입력 문장이 제한된다. 둘째, NER 기반 추출 결과는 세포 유형, 하위 세포 유형, positive marker, negative marker, evidence sentence를 하나의 검토 가능한 후보 레코드로 구조화하는 데 한계가 있다.

최근 대형 언어 모델 (large language model, LLM)은 기존 데이터셋의 라벨 오류를 재검토하고, 정보 추출 결과를 구조화하는 데 활용되고 있다 [4]. LLM 기반 라벨 정제와 프롬프트 기반 정보 추출은 일반적인 자연어처리 연구에서도 활용되어 온 접근법이지만, 본 연구의 차별성은 이를 scRNA-seq 세포 유형 주석을 위한 문헌 기반 세포 유형-마커 큐레이션 과정에 통합했다는 점에 있다. 구체적으로 본 연구는 기존 문장 라벨의 오류 가능성을 고려하여 marker sentence classifier를 개선하고, 선별된 문장에서 세포 유형-마커 쌍과 근거 문장을 함께 정리한다. 이를 통해 PubMed 문헌 수집부터 POS 후보 문장 선별, 세포 유형-마커 쌍 추출, 후보 데이터베이스 정리까지 연결하는 LLM 기반 큐레이션 에이전트 CMAgent (Cell type-Marker curation Agent)를 제안하며, 반복적인 문헌 검토와 수동 주석 부담을 줄이는 것을 목표로 한다.

2. 설계 및 방법

2.1 전체 프레임워크

[그림 1]은 본 연구에서 제안하는 CMAgent의 전체 workflow를 나타낸다. 상단의 1~6단계는 PubMed 문헌으로부터 세포 유형-마커 후보를 추출하고 데이터베이스 형태로 정리하는 전체 동작 흐름이다. 하단의 두 모듈은 본 연구에서 개선하고자 한 핵심 구성 요소를 나타낸다. 왼쪽의 sentence classifier refinement 모듈은 기존 문장 라벨의 오류 가능성을 줄이고 marker sentence classifier를 재학습하는 과정이다. 오른쪽의 prompt-based cell

---

[†]본 논문의 공동 제1저자임.

※ 본 연구는 보건복지부의 재원으로 한국보건산업진흥원의 보건의료기술 연구개발사업 지원에 의하여 이루어진 것임 (RS-2024-00403375).
※ 이 성과는 과학기술정보통신부의 재원으로 한국연구재단의 지원을 받아 수행된 연구임 (RS-2025-24534272).
※ 본 연구는 산업통상자원부의 재원으로 국가표준기술력향상사업 지원에 의하여 수행된 것임 (K_G012002235304).

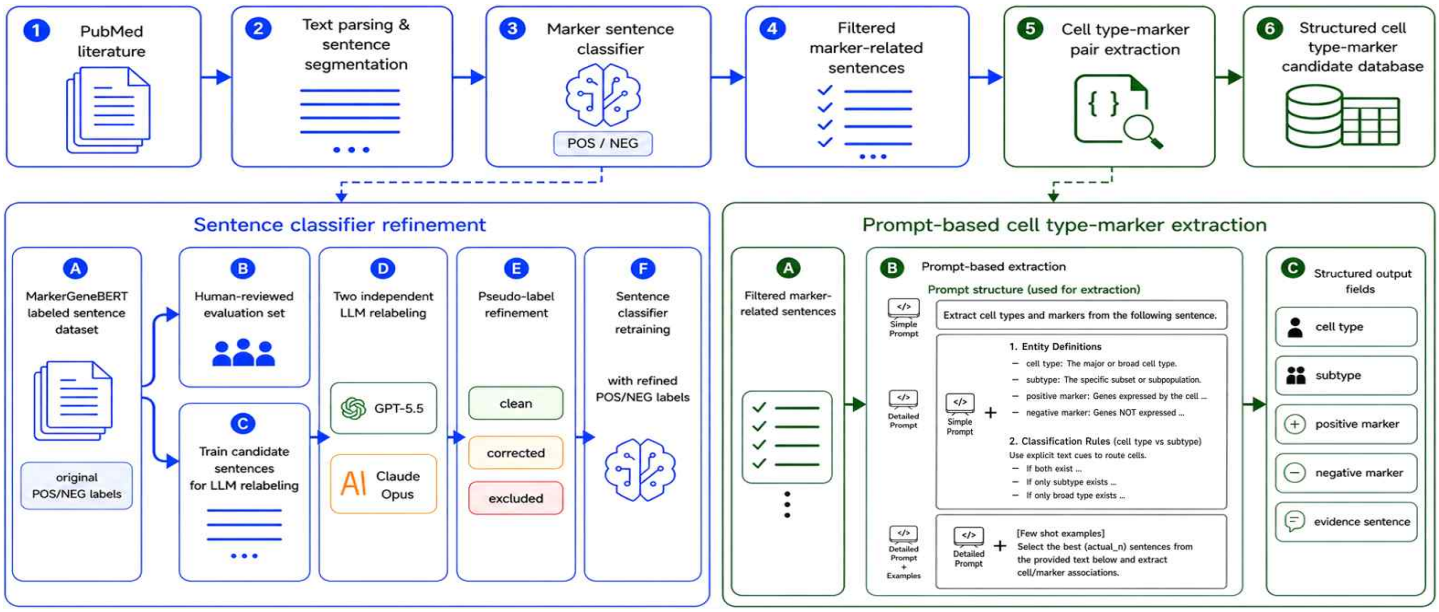


그림 1. CMAgent의 전체 workflow

type-marker extraction 모듈은 선별된 POS 후보 문장에서 세포 유형-마커 쌍과 이를 뒷받침하는 근거 문장을 추출하는 과정이다.

2.2 문헌 자동 수집 및 문장 후보 생성

[그림 1]의 상단 1~2단계는 문헌 자동 수집과 문장 후보 생성 과정이다. CMAgent는 PubMed 문헌을 입력으로 하며, 문헌 접근 가능 여부에 따라 PMC XML, PDF 또는 abstract에서 텍스트를 확보한다. 이후 문헌 텍스트를 문장 단위로 분리하여 marker sentence classifier의 입력으로 사용한다. 다만 본 연구의 실험에서는 문장 필터링 모듈의 학습 및 평가를 위해 MarkerGeneBERT에서 제공한 sentence-level labeled dataset을 사용하였다.

2.3 문장 라벨 정제 및 필터링 모델 학습

[그림 1]의 상단 3단계는 문장 단위로 마커 관련성을 판별하는 marker sentence classifier를 나타내며, 이를 개선하기 위한 구체적인 과정은 [그림 1] 하단 왼쪽의 A~F단계에 해당한다.

A단계에서는 MarkerGeneBERT에서 제공한 labeled sentence dataset을 사용하였다. 이 데이터셋은 original label (기존 POS/NEG 라벨)을 포함하지만, 자동 구축된 silver label이므로 일부 라벨 오류가 포함될 수 있다.

B단계에서는 original label과 사전 LLM prediction이 불일치하여 연구진이 다시 검토한 문장을 human-reviewed evaluation set으로 분리하였고, C단계에서는 전체 labeled sentence dataset에서 evaluation set을 제외한 나머지 문장을 train candidate sentences로 구성하였다.

D단계에서는 train candidate sentences를 두 종류의 LLM에 독립적으로 입력하였다. 구체적으로 OpenAI Batch API의 GPT-5.5-2026-04-23과 OpenRouter API의 anthropic/claude-opus-latest alias를 2026년 4월 실험 시점에 호출하여, 각 문장을 POS, NEG, uncertain 중 하나로 relabeling하였다. 이때 original label은 LLM 입력에 포함하지 않고 sentence만 제공하였다. LLM 출력은 label과 함께 evidence span, gene entity, cell type entity를 포함하도록 하였다.

E단계에서는 두 LLM의 출력 결과를 비교하여 pseudo-label refinement를 수행하였다. 이때 두 LLM이 동일한 POS/NEG 라벨을 출력한 문장을 agreement set으로 정의하였다. Agreement set 중 original label과도 일치하는 문장은 clean set, 두 LLM은 일치하지만 original label과 다른 문장은 corrected set으로 구분하였다. High-confidence set은 agreement set을 기반으로 구성하되, POS로 일치한 문장에는 LLM이 출력한 evidence span이 원문 sentence에 포함되고 gene entity와 cell type entity가 함께 출력되는 조건을 추가로 적용하였다.

F단계에서는 refined POS/NEG labels를 이용해 sentence classifier를 재학습하였다. 라벨 정제 효과를 비교하기 위해 same-split original-label baseline, clean+corrected 모델, high-confidence 모델의 세 가지 학습 조건을 구성하였다.

이후 [그림 1]의 4단계에서는 재학습된 sentence classifier를 이용하여 세포 유형-마커 관계를 포함할 가능성이 높은 POS 후보 문장을 선별한다. 이 POS 후보 문장은 이후 세포 유형-마커 쌍 추출 단계의 입력으로 사용된다.

2.4 프롬프트 기반 세포 유형-마커 쌍 추출

[그림 1]의 5단계는 POS 후보 문장에서 프롬프트를 기반으로 세포 유형-마커 쌍을 추출하는 과정이다. 본 연구에서는 추출 파이프라인 설계를 위해 GPT-4o-mini-2024-07-18 (OpenAI Batch API, 2026년 4월 호출)을 활용하였다. 추출 전략은 모델에 부여되는 제약 조건과 정보량에 따라 기초 프롬프트 (Simple Prompt), 상세 프롬프트 (Detailed Prompt), 예시 포함 프롬프트 (Detailed Prompt + Examples)의 세 가지 방법론으로 구성하였다 [5]. 이후 6단계에서는 추출된 세포 유형-마커 쌍을 구조화하여 통합 데이터베이스 형태로 정리하고, 중복 제거를 거쳐 최종 활용이 가능한 후보 데이터베이스를 구축한다.

3. 실험 및 결과

3.1 문장 라벨 정제 결과

표 1. Sentence label refinement results

Set	Count	POS	NEG
Train candidate sentences	23261	-	-
Agreement set	14756	4770	9986
Clean set	10276	299	9977
Corrected set	4480	4471	9
High-confidence set	14574	4588	9986
Conflict/uncertain/error	8505	-	-

[표 1]은 23,261개의 train candidate sentences에 대한 pseudo-label refinement 결과를 요약한 것이다. 이를 바탕으로 sentence classifier를 재학습하였다.

3.2 문장 필터링 모델 성능

문장 필터링 모델의 성능 평가는 human-reviewed evaluation set을 validation set과 test set으로 나누어 수행하였다. 먼저 validation set에서 threshold를 결정한 뒤, 이를 test set에 고정 적용하였다. 구체적으로 POS 200개와 NEG 200개로 구성한 validation set에서 precision 0.55 이상을 만족하는 threshold 중 recall이 가장 높은 값을 선택하였고, 남은 POS 277개와 NEG 277개로 구성한 balanced test set에서 precision, recall, F1-score를 측정하였다.

표 2. Performance comparison of sentence filtering models

Method	Precision	Recall	F1-score
MarkerGeneBERT	0.571	0.350	0.434
Same-split Original-label Baseline	0.557	0.852	0.673
Refined (Clean + Corrected)	0.498	0.993	0.663
Refined (High-confidence)	0.541	0.939	0.686

[표 2]는 balanced test set에서 sentence classifier의 성능을 비교한 결과이다. LLM pseudo-label 기반 모델 중 refined clean+corrected 모델은 recall 0.993으로 가장 많은 POS 문장을 회수했고, refined high-confidence 모델은 recall 0.939로 높은 회수율을 유지하면서 F1 0.686으로 가장 높은 F1-score를 보였다. 따라서 refined high-confidence 모델은 후보 문장 확장에 유용한 sentence filtering 방법으로 해석할 수 있다.

3.3 세포 유형-마커 쌍 추출 결과

3.3.1 정량적 성능 평가 비교

표 3. Performance comparison across prompting strategies

Method	Precision	Recall	F1-score
Simple Prompt	0.280	0.748	0.407
Detailed Prompt	0.250	0.715	0.370
Detailed Prompt + Examples	0.248	0.707	0.367
MarkerGeneBERT NER	0.179	0.242	0.206

추출 성능 평가를 위해 CellMarker 2.0의 Human Cell Markers 및 Single Cell Markers 데이터를 통합하여 정답 데이터(Ground Truth)를 구축하고, 추출된 세포 유형-마커 쌍의 precision, recall, 그리고 F1-score를 측정하였다 [표 3].

앞서 분류된 POS 후보 문장들을 대상으로 실험한 결과, LLM 기반의 세 가지 프롬프트 방법론 모두 기존 MarkerGeneBERT NER 모델보다 높은 F1-score를 보였으며, 그중 기초 프롬프트가 가장 높은 정량적 성능을 기록하였다.

3.3.2 프롬프트별 정성적 평가 및 분석

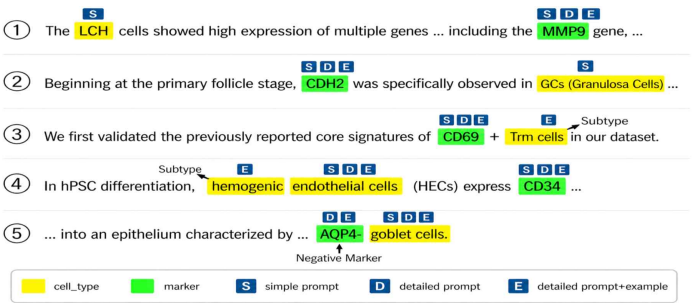


그림 2. 각 프롬프트 방법론별 추출 결과

정량적 지표와 실제 추출 품질의 차이를 규명하기 위해 각 프롬프트 방법론의 추출 결과에 대한 정성적 분석을 실시하였다 [그림 2]. ①번, ②번 사례와 같이 직관적인 세포 유형-마커 관계나 약어가 등장하는 경우, 기초 프롬프트가 누락 없이 비교적 정확한 추출을 수행하여 높은 정량적 성능 지표와 일치하는 경향을 보였다. 반면, ③, ④번 문장처럼 하위 세포 유형이나 수식어가 포함된 복잡한 계층 구조에서는 예시 포함 프롬프트가 메인 세포와 하위 세포를 보다 정밀하게 구조화하는 양상을 보였다. 나아가 ⑤번 사례에서 볼 수 있듯, 상세 프롬프트 및 예시 포함 프롬프트는 부정적 발현 마커까지 식별하고 분리하는 데 상대적으로 우수한 결과를 보였다.

4. 결론 및 향후 연구

본 연구는 PubMed 문헌 수집, 문장 단위 분리, POS 후보 문장 선별, 프롬프트 기반 세포 유형-마커 쌍 추출, 그리고 근거 문장을 포함한 후보 데이터베이스 정리를 하나의 흐름으로 연결하는 LLM 기반 큐레이션 에이전트 CMAgent를 제안하였다. 본 연구에서는 기존 labeled sentence dataset의 original label을 오류 가능성이 있는 silver label로 간주하고, 두 LLM의 agreement를 활용한 pseudo-label refinement를 통해 sentence classifier를 재학습하였다. 그 결과 high-confidence set 기반 모델은 balanced test set에서 가장 높은 F1-score를 보였으며, 후속 세포 유형-마커 쌍 추출에 사용할 POS 후보 문장을 높은 recall로 확보할 수 있었다.

또한 선별된 POS 후보 문장을 대상으로 프롬프트 기반 세포 유형-마커 쌍 추출을 수행한 결과, 세 가지 프롬프트 기반 방법 모두 기존 NER 방식보다 높은 정량 성능을 보였다. 기초 프롬프트는 가장 높은 F1-score를 보였고, 예시 포함 프롬프트는 복잡한 세포 계층 구조나 부정적 발현 마커가 포함된 문장에서 보다 정밀한 구조화 가능성을 보였다. 이를 통해 CMAgent가 대규모 생의학 문헌으로부터 세포 유형-마커 관계를 수집하고, 근거 문장과 함께 후보 데이터베이스로 정리할 수 있음을 확인하였다.

다만 CellMarker 2.0 기반 평가에서는 문헌상 근거가 존재하더라도 기준 데이터베이스에 포함되지 않은 최신 세포 유형-마커 쌍이 false positive로 분류될 수 있는 한계가 있었다. 향후에는 데이터베이스에 없는 후보에 대한 검증 절차를 추가하고, 프롬프트 최적화와 후보 정제 과정을 고도화하여 세포 유형-마커 후보 데이터베이스를 지속적으로 확장할 계획이다.

참고 문헌

[1] Hu, C., et al., "CellMarker 2.0: an updated database of manually curated cell markers in human/mouse and web tools based on scRNA-seq data," Nucleic Acids Research, Vol. 51, No. D1, pp. D870-D876, 2023.

[2] Meng, F.-L., et al., "singleCellBase: a high-quality manually curated database of cell markers for single cell annotation across multiple species," Biomarker Research, Vol. 11, Article No. 83, 2023.

[3] Cheng, P., et al., "A natural language processing system for the efficient extraction of cell markers," Scientific Reports, Vol. 14, Article No. 21183, 2024.

[4] Nahum, O., et al., "Are LLMs better than reported? Detecting label errors and mitigating their effect on model performance," arXiv preprint arXiv:2410.18889v2, 2025.

[5] Ashok, D., and Lipton, Z. C., "PromptNER: prompting for named entity recognition," arXiv preprint arXiv:2305.15444v2, 2023.